1. Problema, decisión y alcance

Proyecto Final Integrador | Machine Learning I | Universidad EAN

Integrantes: Oscar Andrés Ramos Villanueva, Alvaro Cabezas y Nelsón Fabián Manios.

Se explora una decisión hipotética de priorización de evaluaciones para la Secretaría Distrital de Salud de Bogotá. El ejercicio compara el costo de omitir positivos simulados con el de producir alertas innecesarias. No existe una intervención desplegada ni un impacto asistencial medido.

La variable Alcohol es sintética. El archivo original no identifica alcohol por registro. Se heredan reglas aditivas de un notebook previo y se genera una realización aleatoria reproducible. Por tanto, las predicciones describen el simulador, no consumo observado, diagnóstico, causalidad o riesgo futuro.

El paradigma supervisado sirve para estudiar la reproducción de una función probabilística conocida. El objetivo técnico es comparar familias bajo un protocolo sin fuga; el objetivo de decisión experimental es reducir (5 FN + FP) / n frente a una política constante. La relación 5:1 es un supuesto y se somete a sensibilidad.

No se reclaman bonos de datos reales ni de enfoque: los predictores son publicados, pero el resultado es simulado y no se dispone de evidencia histórica suficiente de microcredenciales o R10. No se despliega un modelo clínico.

Las funciones de pérdida de los algoritmos no se confunden con el costo de decisión. La exactitud se reporta como métrica secundaria: un porcentaje alto no basta si los errores importantes permanecen.

2. Datos y representatividad

Fuente: Secretaría Distrital de Salud, VESPA, Datos Abiertos Bogotá. La ficha nacional declara CC BY 4.0. Se adjunta el CSV suministrado por el usuario y se atribuye la fuente; no se afirma haber descargado la copia desde la API.

La copia tiene 101.500 filas, 21 columnas (17 de texto y cuatro enteras), cero duplicados exactos y años 2015–2026. SEXO contiene 44 nulos y PERTENENCIAETNICA 106. Los marcadores textuales también indican ausencia y se documentan por columna en ficha_datos.md y calidad_columnas.csv.

El hash SHA-256 permite identificar la versión exacta. La fecha histórica de descarga no se conoce; la revisión local corresponde al contexto de la sesión del 21 de octubre de 2026. El rango de años no garantiza cobertura anual completa.

Los registros proceden de vigilancia y atención: representan eventos reportados bajo cobertura institucional, no toda la población. Acceso desigual, subregistro y selección institucional limitan representatividad. Sin identificador no se puede comprobar repetición por persona. CASOS es una frecuencia publicada y no se interpreta como reincidencia individual.

SaluData describe policonsumo: un caso puede involucrar varias sustancias. La dicotomía Alcohol/Otras de la simulación simplifica ese fenómeno y no permite inferir la sustancia real. Los atributos sensibles y geográficos requieren revisión por su potencial de estigmatización.

Se mantienen las tres filas intersexuales. Su baja frecuencia impide conclusiones de desempeño fiables para ese segmento; no justifica excluirlas del universo. No se inventan atributos sensibles mediante muestreo.

3. Preparación y diseño sin fuga

La copia cruda se verifica por hash y esquema. La semilla es 2026. Se seleccionan 14 predictores originales y el ajuste final produce 185 columnas transformadas. A diferencia del notebook inicial, no se fuerza un vocabulario de 176 columnas aprendido sobre toda la base.

Partición estratificada: 60,900 registros para desarrollo y CV, 20,300 para seleccionar umbral y 20,300 para prueba. Se separa antes de ajustar imputación o codificación. Los índices son disjuntos; las pruebas de invariantes están en el cuaderno.

Un Pipeline normaliza marcadores y espacios; representa categorías ausentes como Desconocido; aplica OneHotEncoder con categorías desconocidas ignoradas; convierte sitios SI/NO a 1/0. Los seis sitios tienen un valor reservado -1 para ausencia. Cada fold ajusta su propio vocabulario. No se aplica escalamiento porque todas las entradas son indicadores.

Se excluyen el objetivo, la probabilidad generadora, CASOS, vía de llegada a tratamiento y variables temporales. La exclusión temporal responde al simulador heredado, no demuestra irrelevancia del tiempo. No se aplica sobremuestreo: la asimetría se maneja mediante costos y umbral.

La etiqueta se crea con probabilidad base 0,70 y ajustes de sitios, sexo y etapa vital; los límites son 0,05–0,95. No se aprenden distribuciones globales para generarla. Los faltantes aportan cero al ajuste. La nueva política de conservación y el generador default_rng cambian los conteos respecto de la versión previa.

La partición aleatoria sirve para este experimento sintético. Un despliegue real requiere validar por tiempo y, cuando sea posible, por persona. Evitar fuga de transformación no elimina dependencias ni convierte una etiqueta sintética en observada.

4. Modelado y selección

Se compararon DummyClassifier (prior), regresión logística, árbol y bosque aleatorio. Se usaron cinco folds estratificados idénticos, con barajado y semilla fija. Las rejillas se declararon antes de entrenar: C = 0,1/1/10 para logística; profundidad 4/8/12 y hoja mínima 100 para árbol; profundidad 6/12/sin límite, 100 árboles y hoja mínima 30 para bosque.

La búsqueda optimiza costo a un umbral de referencia de 1/6, fijado por la razón de costos 5:1. La familia final minimiza costo CV; ante empates se favorece menor desviación y menor complejidad. La reserva de umbral se utiliza después, sin volver a ajustar parámetros del modelo.

Familia seleccionada: Logistica. Hiperparámetros: {"modelo__C": 0.1}. La selección incluye el baseline: no se garantiza que una familia compleja deba ganar.

La siguiente desviación y varianza son muestrales entre cinco folds. No son intervalos de confianza independientes, ni incertidumbre sobre otras realizaciones del simulador. CV se usa para elegir parámetros y puede resultar optimista; la prueba final se reserva como evaluación separada.

Familia	Costo CV	DE	Varianza	ROC-AUC
Logistica	0.3543	0.00151	2.28e-06	0.7577
Arbol	0.3547	0.00214	4.57e-06	0.7548
Dummy	0.3568	0.00004	2.02e-09	0.5000
Bosque	0.3568	0.00004	2.02e-09	0.7507

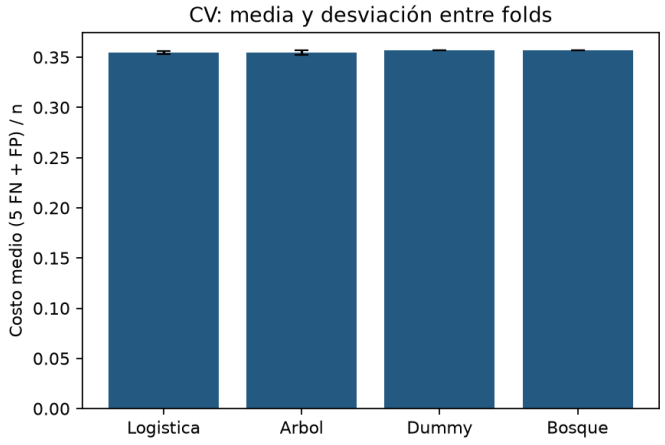
Brecha de costo CV menos entrenamiento: Logistica: 0.0001; Arbol: 0.0008; Dummy: -0.0000; Bosque: -0.0000. Una brecha positiva amplia es compatible con sobreajuste; no constituye una descomposición formal de sesgo y varianza.

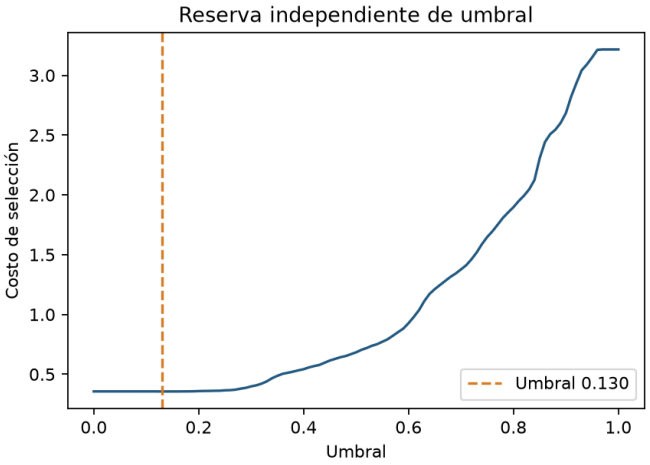
5. Umbral, estabilidad y segmentos

En la reserva independiente se minimizó el costo sobre una rejilla de 0 a 1 (paso 0,01), incluyendo 1/6. Los empates favorecen sensibilidad. El umbral elegido es 0.130. El modelo permanece ajustado solo en desarrollo para no modificar su escala después de elegir el umbral.

Las métricas de esa reserva son de selección y no una evaluación independiente del umbral. Los escenarios 1:1, 2:1, 5:1 y 10:1 muestran cómo cambia la carga de alertas. No se dispone de una restricción real de atención y no se inventa una.

Costo FN/FP	Umbral	Costo	Sensibilidad	Alertas
1	0.520	0.2860	83.2%	71.3%
2	0.290	0.3461	97.9%	94.9%
5	0.130	0.3560	100.0%	99.9%
10	0.130	0.3563	100.0%	99.9%





El diagnóstico por sexo y etapa vital está en diagnostico_segmentos.csv. No se calculan métricas de grupos con menos de 30 filas o una sola clase. Las diferencias reflejan en parte reglas del propio simulador y no prueban equidad real. La importancia por permutación usa reserva de umbral, tres repeticiones y hasta 3.000 registros, al umbral fijo 1/6; no tiene interpretación causal.

6. Evaluación final y límites

Se realizó una sola predicción probabilística sobre prueba, tras congelar familia, hiperparámetros y umbral. La política Dummy se calculó con la prevalencia de desarrollo. Todas las métricas, figuras e intervalos se derivan de esas predicciones; no se decidió ningún ajuste usando prueba.

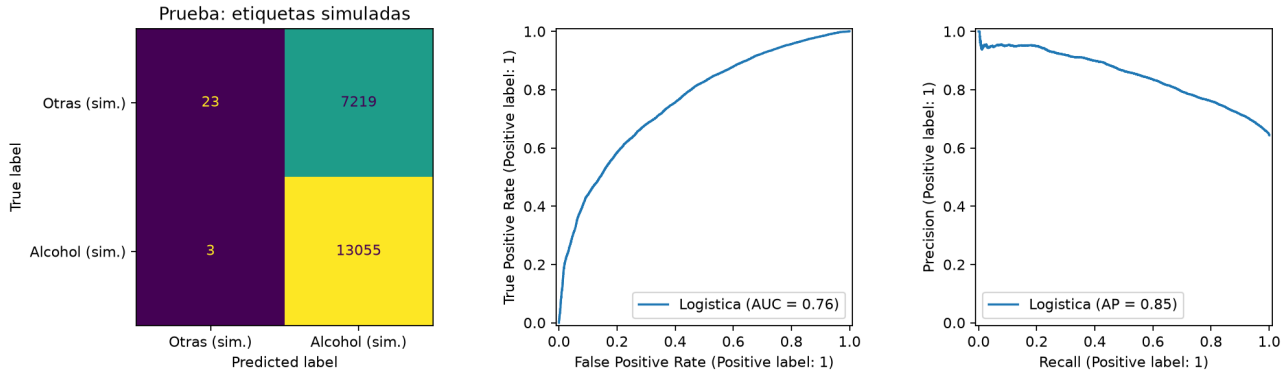
Costo final: 0.3564; baseline: 0.3567; diferencia baseline menos modelo: 0.0004 unidades por registro (0.11% del costo baseline). Esta es una comparación de errores sintéticos, no ahorro monetario ni impacto en salud.

Sensibilidad: 99.98%; precisión: 64.39%; especificidad: 0.32%; F1: 0.7833; exactitud: 64.42%; ROC-AUC: 0.7614; average precision (PR-AUC resumida): 0.8497; Brier: 0.1862.

Alertas: 99.87%. Confusión: TN=23, FP=7219, FN=3, TP=13055. La clase positiva siempre es Alcohol simulado.

Bootstrap pareado de 400 remuestreos: IC percentil 95% del costo [0.3500, 0.3630], y de la diferencia frente a Dummy [-0.0005, 0.0012]. Los intervalos son condicionales al ajuste y a registros tratados como intercambiables. No cubren dependencia entre eventos, otras semillas ni cambios del generador.

El intervalo de la diferencia incluye cero: no hay evidencia concluyente de reducción de costo frente al baseline bajo este análisis. La alerta casi universal ofrece escasa priorización práctica. Una sensibilidad cercana al 100% con especificidad casi nula no implica un modelo útil para administrar recursos limitados.



La simulación no puede validar un resultado que el CSV no observa. Una buena discriminación puede ser consecuencia de recuperar las reglas impuestas. Las probabilidades no están calibradas frente a diagnósticos reales.

7. Decisión, gobernanza y seguimiento

Decisión recomendada: conservar el trabajo como demostración académica reproducible y no desplegarlo para evaluación individual, priorización territorial real o asignación asistencial. El siguiente paso es obtener un resultado observado con definición explícita y documentar la unidad de análisis.

Antes de un piloto: validar etiquetas de varias sustancias cuando corresponda, verificar permisos y minimización de datos, acordar costos y capacidad, separar por tiempo y persona, evaluar calibración y desempeño por grupos con incertidumbre, y comparar con la práctica existente.

Roles propuestos: el custodio de datos valida procedencia, calidad y acceso; el equipo analítico revisa generalización, deriva y sesgos; un responsable de salud define la decisión y sus salvaguardas. No se atribuyen estos roles como trabajo histórico de los integrantes.

Seguimiento propuesto para un futuro piloto validado: revisión mensual de faltantes, categorías nuevas, cambios de cobertura y volumen de alertas; evaluación periódica de sensibilidad y precisión cuando lleguen resultados observados. Los límites aceptables deben acordarse antes de operar. Suspender si cambia el resultado, falta evidencia de validez o se detecta perjuicio no resuelto.

La fuente pública no elimina riesgos de combinación de cuasi-identificadores. Este repositorio utiliza la copia pública suministrada, sin intentar reidentificar personas. No se exportan listas de personas priorizadas. El uso futuro deberá revisar la normativa y autorización aplicables con la entidad responsable.

La capacidad real y las pérdidas monetarias no están documentadas. Ninguna cifra del ejercicio debe convertirse en una promesa de cobertura, reducción de consumo o prevención de enfermedad.

8. Reproducibilidad, equipo y referencias

Ejecución completa desde núcleo nuevo: 8/8 celdas de código, sin errores; duración 114.3 segundos. El registro y hash del notebook están en validacion_ejecucion.json. Semilla 2026, CSV versionado por SHA-256 y dependencias fijadas en requirements.txt.

La ejecución usa únicamente rutas relativas y no necesita conexión al portal. ejecutar_notebook.py crea un kernel local aislado. generar_entregables.py transforma los resultados ya calculados en documentos y ZIP; no vuelve a evaluar prueba.

Los nombres del equipo proceden del original. No se conoce el reparto histórico de contribuciones ni el uso previo de IA por integrante. declaracion_IA.md documenta esta intervención y los datos que el equipo debe confirmar. No se inventan entregas R10–R18: trazabilidad_CRISP_DM.md vincula los artefactos consolidados actualmente.

Secretaría Distrital de Salud. (s. f.). Consumo abusivo o problemático de sustancias psicoactivas [Conjunto de datos]. Datos Abiertos Bogotá. https://datosabiertos.bogota.gov.co/dataset/consumo-abusivo-o-problematico-de-sustancias-psicoactivas

Secretaría Distrital de Salud. (s. f.). Consumo abusivo o problemático de sustancias psicoactivas en Bogotá D. C. SaluData. https://saludata.saludcapital.gov.co/osb/indicadores/consumo-abusivo-spa/

Chapman, P., Clinton, J., Kerber, R., Khabaza, T., Reinartz, T., Shearer, C., & Wirth, R. (2000). CRISP-DM 1.0: Step-by-step data mining guide. SPSS.

Scikit-learn developers. (s. f.). Common pitfalls and recommended practices. https://scikit-learn.org/stable/common_pitfalls.html

Scikit-learn developers. (s. f.). Tuning the decision threshold for class prediction. https://scikit-learn.org/stable/modules/classification_threshold.html